
Theoretical Insights on Training Instability in Deep Learning

Slide tiếng Việt cho video tutorial

Thông điệp chính


Training instability không chỉ là lỗi cần né; nó tiết lộ cách optimizer tương tác với loss landscape.

Biên soạn lại từ slide bài giảng gốc

Mục tiêu của video

Sau video, người xem nắm được

- ▶ **Loss spike** và training instability đến từ đâu.
- ▶ Khác biệt giữa *infinitesimal*, *small* và *large stepsize*.
- ▶ Vì sao large stepsize có thể **tăng tốc optimization**.
- ▶ Vì sao large stepsize có thể **giảm overfitting** thông qua flat minima.



Gợi ý lời thoại: Mở đầu bằng câu hỏi gần gũi: “Tại sao loss đang giảm bỗng nhiên nhảy vọt? Có phải model hỏng không?” **Visual Note (Manim):** Dùng curve loss đang giảm rồi spike đỏ bật lên; camera pan

từ spike sang câu hỏi mở đầu.
Theoretical Insights on Training Instability

Câu chuyện lớn: Stability không chỉ là lỗi kỹ thuật

- ▶ Trong deep learning hiện đại, các learning rate hiệu quả thường nằm ở vùng **large stepsize**.
- ▶ Large stepsize làm loss không còn giảm đều từng bước: ta thấy **oscillation**, **spike**, thậm chí divergence.
- ▶ Nhưng nghịch lý là: cùng cơ chế gây bất ổn đó lại có thể giúp model đi tới nghiệm **phẳng hơn** và **generalize tốt hơn**.

Thông điệp chính

Training instability không chỉ là “bug cần né”. Nó là dấu hiệu cho thấy optimizer đang tương tác mạnh với hình học của loss landscape.

$$\text{Sharpness}(\theta) := \lambda_{\max}(\nabla^2 L(\theta))$$

Visual Note (Manim): Zoom vào loss landscape 3D, highlight vùng sắc bằng Hessian eigenvalue lớn; chuyển cảnh sang đồ thị loss spike.

Ba chế độ của stepsize

Chế độ	Hành vi	Cách nghĩ
Infinitesimal	$\eta \rightarrow 0$, gần gradient flow	Rất ổn định, nhưng chậm
Small	Loss giảm đơn điệu nếu $\eta < 2/\ \nabla^2 L\ $	Nền tảng của lý thuyết optimization cổ điển
Large	Loss có thể tăng, dao động, spike	Không ổn định cục bộ, nhưng có bias chọn nghiệm phẳng


$$\eta < \frac{2}{\sup \|\nabla^2 L(\cdot)\|} \iff \text{vùng small stepsize}$$

Gợi ý lời thoại: Ở đây nên nói chậm: “large” không có nghĩa là con số lớn tuyệt đối; nó lớn so với độ cong local của loss. **Visual Note (Manim):** Tạo thanh trượt learning rate: khi η vượt ngưỡng $2/\lambda_{\max}$, màu chuyển từ xanh sang cam/đỏ.

Gradient flow: khi bước đi cực nhỏ

$$\begin{aligned}d\theta &= -\nabla L(\theta) dt \\dL(\theta) &= \nabla L(\theta)^\top d\theta \\&= -\|\nabla L(\theta)\|^2 dt \leq 0\end{aligned}$$

- ▶ Loss luôn giảm theo thời gian liên tục.
- ▶ Momentum và SGD cũng có thể được xấp xỉ bằng ODE/SDE trong giới hạn bước nhỏ.
- ▶ Với Adam/adaptivity, continuous limit phức tạp hơn.



Descent lemma: vì sao small stepsize an toàn?

Với Gradient Descent:

$$\theta_+ = \theta - \eta \nabla L(\theta)$$

Phân rã Taylor cho ta điểm tựa lý thuyết:

$$L(\theta_+) \leq L(\theta) - \eta \|\nabla L(\theta)\|^2 \left(1 - \frac{\eta}{2} \|\nabla^2 L(\nu)\|\right).$$

Ý nghĩa hình học

Nếu $\eta < 2/\|\nabla^2 L(\nu)\|$, ngoặc cuối dương nên loss giảm. Khi η quá lớn, dấu hiệu giảm bị phá vỡ.

Visual Note (Manim): Manim viết từng phần Taylor: linear term màu xanh kéo xuống, quadratic remainder màu đỏ kéo lên; cho η lớn làm term đỏ thắng.

Large stepsize: ổn định động lực học thay vì giảm từng bước

- ▶ Khi η lớn, descent lemma không còn đảm bảo loss giảm từng bước.
- ▶ Tuy vậy, GD/SGD vẫn có thể hội tụ theo nghĩa động lực học: quỹ đạo dao động nhưng không nổ tung.
- ▶ Nếu hội tụ về θ_∞ , điều kiện ổn định thường buộc độ cong tại điểm đó phải nhỏ:


$$\|\nabla^2 L(\theta_\infty)\| \lesssim \frac{2}{\eta}.$$

Sharpness penalty

Learning rate càng lớn, optimizer càng khó đứng yên ở nghiệm sắc nhọn. Nó bị “đẩy” về vùng phẳng hơn.

Progressive sharpening và Edge of Stability

- ▶ Ban đầu training có thể nằm trong vùng an toàn.
- ▶ Trong quá trình học, sharpness tăng dần: **progressive sharpening**.
- ▶ Khi sharpness chạm gần $2/\eta$, loss bắt đầu dao động quanh rìa ổn định: **edge of stability**.



$$\lambda_{\max}(\nabla^2 L(\theta_t)) \approx \frac{2}{\eta}$$

Gợi ý lời thoại: Đây là một trong các hình ảnh quan trọng nhất: không phải training “ổn định tuyệt đối”, mà nó học ngay sát biên ổn định. **Visual Note (Manim):** Vẽ parabol rồi rạc; viên bi vàng nhảy qua lại giữa hai vách khi $\eta > 2/\lambda$, rồi ổn định quanh đường $2/\eta$.

Phần 1: Large stepsize giúp optimization nhanh hơn

Mental model cổ điển

Muốn nhanh và an toàn: chọn learning rate đủ nhỏ để loss giảm đều.

Mental model hiện đại

Trong một số bài toán ML, large stepsize tạo các pha **stable** và **unstable**. Pha unstable không vô nghĩa: nó giúp quỹ đạo thoát khỏi vùng kém thuận lợi và đi dọc theo valley nhanh hơn.

- ▶ Ví dụ trong bài giảng: logistic regression trên dữ liệu separable.
- ▶ GD với large stepsize có thể đạt tốc độ tốt hơn phân tích small-stepsize.
- ▶ Adaptive large stepsize thậm chí có thể đạt minimax optimal trong setting phù hợp.

Visual Note (Manim): Chia màn hình: small step đi từng bước ngắn trong valley; large step bật xa hơn nhưng vẫn được valley giữ lại.

Stable phase vs Unstable phase

Stable phase

- ▶ Loss giảm sau mỗi bước.
- ▶ Có thể phân tích gần giống theory cổ điển.
- ▶ Quỹ đạo đi chậm nhưng kiểm soát tốt.

Unstable phase


- ▶ Loss có thể tăng hoặc dao động.
- ▶ Không nhất thiết là thất bại.
- ▶ Có thể tạo acceleration bằng cách “nhảy” qua vùng cong lớn.



Visual Note (Manim): Timeline đổi màu theo pha stable/unstable; mỗi đoạn unstable có hiệu ứng rung nhẹ, sau đó quay về stable.

Valley + basin: hình ảnh nên dùng khi giải thích

- ▶ Loss landscape không giống một cái bát quadratic đơn giản.
- ▶ Nó có valley dài, basin rộng, vùng cong sắc và vùng phẳng.
- ▶ Small stepsize đi cẩn thận từng bước; large stepsize có thể “lướt” qua valley nhanh hơn nhưng dễ rung.



Tóm tắt Optimization

1. Small stepsize cho ta lý thuyết đẹp: descent lemma, convergence rate, gradient flow.
2. Deep learning thực tế thường chạy ở vùng large stepsize để học nhanh.
3. Large stepsize gây instability, nhưng cũng tạo **implicit bias** chống lại sharp minima.
4. Câu hỏi mở: thiết kế scheduler, warmup, normalization, preconditioning sao cho tận dụng được instability mà không divergence.

Phần 2: Large stepsize và Generalization

Câu hỏi mới

Nếu có rất nhiều nghiệm fit training data, GD với large stepsize sẽ tìm nghiệm **generalize** hay nghiệm **overfit**?


- ▶ Deep learning hiện đại thường overparameterized: capacity không còn là rào cản chính.
- ▶ Với label noise, model vẫn có thể đạt training loss rất thấp nhưng test error cao.
- ▶ Vì vậy, generalization phụ thuộc mạnh vào **implicit regularization** của optimizer, kiến trúc, loss, và dữ liệu.

Flat minima: từ parameter space đến function space

- ▶ Large stepsize khiến GD tránh vùng curvature cao.
- ▶ Trong nhiều setting, flatness trong parameter space kéo theo ràng buộc độ mượt của hàm học được.
- ▶ Với two-layer ReLU univariate và square loss, stable minima liên hệ với weighted total variation class:

$$\int |f''(x)| g(x) dx \leq \frac{2}{\eta}$$

Visual Note (Manim): Biến đường zig-zag overfit thành đường smooth; công thức TV xuất hiện như “rào chắn” độ cong.



Tại sao nghiệm nội suy nhiều thường sắc?

- ▶ Nếu label có noise, một nghiệm fit hoàn hảo phải “uốn” theo các điểm nhiễu.
- ▶ Việc uốn quá mạnh làm hàm có curvature/variation lớn.
- ▶ Trong parameter space, các nghiệm như vậy thường nằm ở vùng sharp: chỉ cần perturb nhỏ là loss tăng nhiều.
- ▶ Large learning rate không ổn định ở đó, nên GD có xu hướng tránh các nghiệm overfit sắc nhọn.

Cách nói dễ hiểu trong video


Large stepsize giống như đi xe nhanh trên đường gồ ghề: chỗ quá sắc/quá hẹp thì không thể dừng lại ổn định, chỉ vùng rộng và phẳng mới giữ được quỹ đạo.

Visual Note (Manim): Dựng các điểm dữ liệu có noise; một curve cố nội suy mọi điểm rung mạnh, curve smooth bỏ qua noise và được tô xanh.

Case study thực nghiệm: khi model vẫn fit được nhiều

- ▶ Các thí nghiệm kiểu *shuffled labels* / *shuffled pixels* cho thấy neural nets có thể fit cả dữ liệu bị phá cấu trúc.
- ▶ Vì vậy, câu hỏi không chỉ là “model có đủ capacity không”, mà là optimizer chọn nghiệm nào trong vô số nghiệm fit training data.
- ▶ Large stepsize và flatness đóng vai trò như một **implicit filter**: nghiệm quá sắc hoặc quá local sẽ khó ổn định.

Visual Note (Manim): Manim tạo lưới pixel bị shuffle, label đổi ngẫu nhiên; sau đó hiện nhiều nghiệm, nghiệm sharp bị tô đỏ.



shuffled pixels
/ labels

fit được
nhưng dễ
overfit

Vai trò của dữ liệu, loss và kiến trúc

Large stepsize không hoạt động một mình. Generalization còn phụ thuộc vào:

- ▶ **Data distribution**: dữ liệu có cấu trúc low-dimensional hay không.
- ▶ **Data augmentation**: ví dụ mixup có thể làm hình học dữ liệu “mượt” hơn.
- ▶ **Loss function**: square loss và logistic loss cho các câu chuyện khác nhau.
- ▶ **Architecture**: bias/no-bias, ReLU, depth, normalization, weight decay.
- ▶ Ví dụ thực tế để kể trong video: nhiều GPT-style Transformer bỏ bias; đây là một hint thú vị khi bàn về neural shattering và geometry của kiến trúc.

Điểm cần nhấn mạnh

Không nên nói “flat minima luôn generalize tốt”. Đúng hơn: flatness hữu ích khi nó tương tác đúng với cấu trúc dữ liệu và model.

Visual Note (Manim): Dùng sơ đồ 4 mảnh ghép: data, loss, architecture, optimizer; mảnh optimizer phát sáng nhưng không đứng một mình.

High dimension: neural shattering và curse of dimensionality

- ▶ Trong không gian nhiều chiều, mỗi neuron có thể “bắt” một điểm dữ liệu riêng lẻ, nhất là gần biên support.
- ▶ Hiện tượng này gọi là **neural shattering**: model chia vụn dữ liệu theo cách rất local.
- ▶ Khi đó flatness-induced generalization khó hơn; cần thêm điều kiện như weight decay, bỏ bias, data augmentation, hoặc giả thiết low-dimensional structure.


Thông điệp cho người xem

Large stepsize là một nguồn regularization mạnh, nhưng không thay thế hoàn toàn thiết kế dữ liệu và kiến trúc.

Visual Note (Manim): Vẽ neuron như một half-space đang “bắt” một điểm biên; sau đó thêm weight decay/no-bias làm vùng bắt điểm co lại.

Edge of Stability cũng giải thích U-shape risk curve

- ▶ Learning rate quá nhỏ: học chậm, regularization yếu.
- ▶ Learning rate vừa lớn: chọn nghiệm phẳng hơn, test risk tốt hơn.
- ▶ Learning rate quá lớn: training mất ổn định hoặc divergence.



Visual Note (Manim): Animate điểm chạy trên trục η : trái học chậm, giữa sweet spot sáng xanh, phải rung đỏ/diverge.

Tóm tắt Generalization

1. Overparameterized networks có nhiều nghiệm nội suy, nên optimizer quyết định nghiệm nào được chọn.
2. Large stepsize tạo áp lực tránh sharp minima, từ đó đóng vai trò implicit regularizer.
3. Trong các mô hình đơn giản, flatness có thể dịch thành ràng buộc độ mượt trong function space.
4. Trong high dimension, cần chú ý data geometry, augmentation, weight decay và kiến trúc.

Tài liệu tham khảo

- ▶ Cohen, Kaur, Li, Kolter, Talwalkar. *Gradient descent on neural networks typically occurs at the edge of stability*. ICLR 2021.
- ▶ Wu, Ma, E. *How SGD selects the global minima in over-parameterized learning: a dynamical stability perspective*. NeurIPS 2018.
- ▶ Damian, Ma, Lee. *Label noise SGD provably prefers flat global minimizers*. NeurIPS 2021.
- ▶ Li, Wang, Arora. *What happens after SGD reaches zero loss? A mathematical framework*. ICLR 2022.
- ▶ Qiao, Zhang, Singh, Soudry, Wang. *Stable Minima Cannot Overfit in Univariate ReLU Networks*. 2024.